Centro Universitário de Excelência
Sistemas de Informação

Técnicas de Pré-processamento de dados

Autor: Bruno Sampaio Silva
Levi Falcão de Queiroz
Moisés de Souza Oliveira
Raphael dos Santos Moreira

Feira de Santana, 2026

Agenda

Explicar as técnicas de pré-processamento implementadas no projeto, incluindo tratamento de dados ausentes, normalização de dados e codificação de variáveis categóricas, demonstrando sua aplicação no dataset do Spotify.

1. Introdução:
Contextualização e resumo do que será apresentado

2.Classificação:
Apresentação das principais categorias de técnicas de pré-processamento

3. Dados Ausentes e Nulos:
Explicação das estratégias para identificar, remover ou substituir valores ausentes no dataset.

4. Scaler:
Técnicas de normalização de dados utilizadas para padronizar valores numéricos.

5. Encoders:
Técnicas de normalização de dados utilizadas para padronizar valores numéricos.

6. Pré-processamento no Spotify:
Demonstração da aplicação das técnicas de pré-processamento no dataset do Spotify

Introdução

- Dende-Software House
- Somos Trainees (dendezeiros)
- Biblioteca de preprocessamento de dados

Anteriormente

- Statistics
- Responsável por fazer cálculos estatísticos em um dataset
- Classificação de cada uma delas.

Categoria	*Método*
Tendência Central	mean(), median(), mode()
Dispersão	variance(), stdev()
Relacionamento	covariance()
Frequências	absolute_, relative_, cumulative_
Distribuicão	quartiles(), histogram()
Probabilidade	conditional_probability()

Técnica de pré-processing

- Pré-processing
- Formada por 4 classes
- Cada classe tem um método responsável por tratar os dados

Classe	*Responsabilidade Principal*
MissingValueProcessor	Tratamento de dados ausentes
Scaler	Escalonamento e Normalização
Encoder	Codificacão de variáveis categóricas
Preprocessing	Orquestrador

Classificação e Métodos

- O pré-processamento inclui:
  - Tratamento de Dados Ausentes e Nulos
  - Transformadores de Escala
  - Codificadores

Classificação	Classe	SHOES
Dados Ausentes	MissingValueProcessor	Isna, notna, fillna, dropna
Escala	Scaler	Min-Max, Standard
Codificação	Encoder	Label Encoding, One-Hot Encoding

Dados Ausentes e Nulos

- isna e notna:
  - Retorna colunas regulares ou irregulares
  - Não modifica o dataset

```
dataset_musicas = {
    "música": ["A", "B", "C"],
    "popularity": [85, None, 70],
    "followers": [1200000, 200000, None]
}
```

música	popularity	followers
A	85	1.200.000
B	None	200.000
C	70	None

Dados Ausentes e Nulos

- isna e notna:
  - Retorna colunas regulares ou irregulares
  - Não modifica o dataset

```
dataset_musicas = {
    "música": ["A", "B", "C"],
    "popularity": [85, None, 70],
    "followers": [1200000, 200000, None]
}
```

música	popularity	followers
A	85	1.200.000
B	None	200.000
C	70	None

música	popularity	followers
B	None	200.000
C	70	None

Dados Ausentes e Nulos

- isna e notna:
  - Retorna colunas regulares ou irregulares
  - Não modifica o dataset

```
dataset_musicas = {
    "música": ["A", "B", "C"],
    "popularity": [85, None, 70],
    "followers": [1200000, 200000, None]
}
```

música	popularity	followers
A	85	1.200.000
B	None	200.000
C	70	None

música	popularity	followers
B	None	200.000
C	70	None

música	popularity	followers
A	85	1.200.000

Dados Ausentes e Nulos

- fillna e dropna:
  - Define uma estratégia de tratamento.
  - Modifica o dataset

```
dataset_musicas = {
    "música": ["A", "B", "C"],
    "popularity": [85, None, 70],
    "followers": [1200000, 200000, None]
}
```

música	popularity	followers
A	85	1.200.000
B	None	200.000
C	70	None

Dados Ausentes e Nulos

- fillna e dropna:
  - Define uma estratégia de tratamento.
  - Modifica o dataset
  - fillna

música	popularity	followers
A	85	1.200.000
B	0	200.000
C	70	0

```
dataset_musicas = {
    "música": ["A", "B", "C"],
    "popularity": [85, None, 70],
    "followers": [1200000, 200000, None]
}
```

música	popularity	followers
A	85	1.200.000
B	None	200.000
C	70	None

Dados Ausentes e Nulos

- fillna e dropna:
  - Define uma estratégia de tratamento.
  - Modifica o dataset
  - fillna / dropna

música	popularity	followers
A	85	1.200.000
B	0	200.000
C	70	0

música	popularity	followers
A	85	1.200.000

```
dataset_musicas = {
    "música": ["A", "B", "C"],
    "popularity": [85, None, 70],
    "followers": [1200000, 200000, None]
}
```

música	popularity	followers
A	85	1.200.000
B	None	200.000
C	70	None

Transformadores de Escala

- Min-Max:
  - Equilibrar grandezas numéricas distintas
  - MinMax: $$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$
  - Eliminar vieses matemáticos
  - Intervalo de [0,1]

música	popularity	followers
A	85	1.200.000
B	30	200.000
C	70	950.000

música	popularity	followers
A	0.92	1.00
B	0.00	0.00
C	0.73	0.75

Transformadores de Escala

- Standard-Scale:
  - Equilibrar grandezas numéricas distintas
  - Fórmula: $z = \frac{x - \mu}{\sigma}$
  - Eliminar vieses matemáticos
  - Média = 0
  - Desvio padrão = 1

música	popularity
A	85
B	30
C	70

música	popularity
A	0.88
B	−1.09
C	0.21

Quando usar?

- Min-Max:
  - Os dados não seguem distribuição normal
  - É importante manter a proporção original dos valores
  - Os algoritmos trabalham melhor com valores entre 0 e 1

- Standard:
  - Os dados possuem distribuição aproximadamente normal
  - O algoritmo considera média e variância
  - Há presença de outliers moderados

Encoder

- Classe Encoder:
  - Traduzir categorias textuais para números
  - Fazer a maquina compreender
  - Dados categóricos

música	**album_type**
A	album
B	single
C	album

Encoder

- Label Encoding:
  - Cada categoria é representada por um número
  - Menos complexo
  - Pode induzir viés de ordem

música	**album_type**
A	album
B	single
C	album

música	**album_type**
A	0
B	1
C	0

Encoder

- One-Hot Encoding:
  - Cria uma matriz
  - Apenas 1 e 0
  - Mais complexo
  - Sem viés de ordem

música	**album_type**
A	album
B	single
C	album

música	**album_type_album**	**album_type_single**
A	1	0
B	0	1
C	1	0

Pré-processamento (Spotify)

- Utilizando a biblioteca no dataset:
  - Isna()
  - dropna()
  - One-Hot
  - Min-Max

Pré-processamento (Spotify)

- Isna:
  - Retorna Linhas Inválidas
  - Aplicada Sobre artist_genres

track_name Title of the track as listed on Spotify. May include featured artists or remix labels.	artist_name Name of the primary artist associated with the track. May include solo artists, bands, or collaborative acts.	artist_genres List of genres associated with the artist.
7462 unique values	Taylor Swift 4% The Weeknd 2% Other (8117) 95%	N/A 39% soundtrack 4% Other (4876) 57%
Trippy Mane (ft. Project Pat)	Diplo	moombahton
OMG!	Yelawolf	country hip hop, southern hip hop
Hard 2 Find	Riff Raff	N/A
Still Get Like That (ft. Project Pat & Starrah)	Diplo	moombahton

Pré-processamento (Spotify)

```
Total de linhas no dataset (ANTES DO ISNA): 8582
Total de linhas com artist_genres ausente (ISNA): 3361
track_name                                        | artist_name              | artist_genres
--------------------------------------------------------------------------------------------------
Hard 2 Find                                       | Riff Raff                | N/A
Te Procuro na Cidade                              | AZERDK                   | N/A
Cupido Vagabundo                                  | Toni dos Anjos           | N/A
Stray                                             | What Matters The Most    | N/A
Root of all Evil                                  | Daniel Caesar            | N/A
```

Pré-processamento (Spotify)

- dropna:
  - Retira Linhas Inválidas do dataset
  - Valores: vazios, n/a, None e etc.

track_name Title of the track as listed on Spotify. May include featured artists or remix labels.	artist_name Name of the primary artist associated with the track. May include solo artists, bands, or collaborative acts.	artist_genres List of genres associated with the artist.
7462 unique values	Taylor Swift 4% The Weeknd 2% Other (8117) 95%	N/A 39% soundtrack 4% Other (4876) 57%
Trippy Mane (ft. Project Pat)	Diplo	moombahton
OMG!	Yelawolf	country hip hop, southern hip hop
Hard 2 Find	Riff Raff	N/A
Still Get Like That (ft. Project Pat & Starrah)	Diplo	moombahton

Pré-processamento (Spotify)

```
DEPOIS DO DROPNA
Total de linhas restantes: 5221

track_name                                          | artist_name              | artist_genres
-----------------------------------------------------------------------------------------------------------------------
Trippy Mane (ft. Project Pat)                       | Diplo                    | moombahton
OMG!                                                | Yelawolf                 | country hip hop, southern hip hop
Still Get Like That (ft. Project Pat & Starrah)     | Diplo                    | moombahton
ride me like a harley                               | Rumelis                  | dark r&b
BLEED                                               | Minzie                   | dark r&b
```

Pré-processamento (Spotify)

- Min-Max:
  - Iguala as colunas entre [0,1]
  - Aplicação sobre 2 colunas
  - track_popularity [0,100]
  - artist_followers [0, Max]

track_name Title of the track as listed on Spotify. May include featured artists or remix labels.	track_popularity Popularity score assigned by Spotify (0–100), based on recent streaming activity. A score of 0 may indicate	artist_followers Number of followers the artist has on Spotify.
7462 unique values	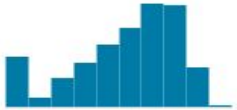 0 99	 0 146m
Trippy Mane (ft. Project Pat)	0	2812821
OMG!	0	2363438
Hard 2 Find	4	193302
Still Get Like That (ft. Project Pat & Starrah)	30	2813710

Pré-processamento (Spotify)

```
ANTES DO MINMAX (5 primeiras linhas):

track_name                                                | track_popularity   | artist_followers
-------------------------------------------------------------------------------------------------------
Trippy Mane (ft. Project Pat)                             |               0.00 |         2812821.00
OMG!                                                      |               0.00 |         2363438.00
Hard 2 Find                                               |               4.00 |          193302.00
Still Get Like That (ft. Project Pat & Starrah)           |              30.00 |         2813710.00
ride me like a harley                                     |               0.00 |            8682.00

DEPOIS DO MINMAX (5 primeiras linhas):

track_name                                                | track_popularity   | artist_followers
-------------------------------------------------------------------------------------------------------
Trippy Mane (ft. Project Pat)                             |             0.0000 |             0.0193
OMG!                                                      |             0.0000 |             0.0162
Hard 2 Find                                               |             0.0404 |             0.0013
Still Get Like That (ft. Project Pat & Starrah)           |             0.3030 |             0.0193
ride me like a harley                                     |             0.0000 |             0.0001
```

Pré-processamento (Spotify)

- One-Hot Encoding:
  - Aplicação sobre a coluna album_type
  - Coluna do tipo categórica
  - Álbum
  - Single
  - Compilation

track_name Title of the track as listed on Spotify. May include featured artists or remix labels.	album_type Type of album release (e.g., album, single, compilation). Helps distinguish between full-length projects and
7462 unique values	album 68% single 26% Other (507) 6%
Trippy Mane (ft. Project Pat)	album
OMG!	single
Hard 2 Find	single
Still Get Like That (ft. Project Pat & Starrah)	album

Pré-processamento (Spotify)

```
ANTES DO ONE-HOT:

track_name                                                  | album_type
--------------------------------------------------------------------------------
Trippy Mane (ft. Project Pat)                               | album
OMG!                                                        | single
Hard 2 Find                                                 | single
Still Get Like That (ft. Project Pat & Starrah)             | album
ride me like a harley                                       | single

DEPOIS DO ONE-HOT (5 primeiras linhas):

track_name                                                                                  | album_type_album   | album_type_single   | album_type_compilation   |
-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------
Trippy Mane (ft. Project Pat)                                                               | 1                  | 0                   | 0                        |
OMG!                                                                                        | 0                  | 1                   | 0                        |
Hard 2 Find                                                                                 | 0                  | 1                   | 0                        |
Still Get Like That (ft. Project Pat & Starrah)                                             | 1                  | 0                   | 0                        |
ride me like a harley                                                                       | 0                  | 1                   | 0                        |
```

Considerações Finais

- Tratar diferentes representações de ausência como None, N/A e strings vazias.
- Fazer o código mais rápido e evitar validações desnecessárias
- Manter a consistência no dataset
- Desenvolver a classe Pré-processamento
- Entendimento sobre normalização